

RAPORT ANALIZY METYLACJI CpG NANOPORE

Żubr europejski (Bison bonasus) - dwa osobniki względem referencji Bos taurus

1. KRÓTKA CHARAKTERYSTYKA DANYCH WEJŚCIOWYCH

Przeanalizowano dwa zestawy danych z sekwencjonowania długich odczytów, reprezentujące dwa osobniki żubra europejskiego (Bison bonasus):

Próbka A (ID: KB923)

Basecaller : Dorado v0.9.6 | tryb: SIMPLEX

Model : dna_r10.4.1_e8.2_260bps_sup@v4.0.0

Model met. : dna_r10.4.1_e8.2_260bps_sup@v4.0.0_5mCG_5hmCG@v2

Liczba odczytów: 3,764,411 | primary: 3,230,105

Średnia długość odczytu (zmapowane): ~4,945 bp

Próbka B (ID: Zubr-L1792_F)

Basecaller : Dorado v1.0.2 | tryb: DUPLEX

Model : sup,5mCG_5hmCG,6mA (wykrywa również metylację 6mA)

Liczba odczytów: 2,368,994 | primary: 1,619,182

Średnia długość odczytu (zmapowane): ~5,266 bp

Obie próbki składają się z pojedynczych (single-end), długich odczytów typowych dla sekwencjonowania ONT. Odczyty zostały posortowane i zaindeksowane przy użyciu SAMtools v1.19.2. Jako genom referencyjny wykorzystano Bos taurus (bydło), assembly ARS-UCD2.0 / NCBI (bos_taurus.fa), obejmujący 30 autosomów (NC_037328.1–NC_037357.1), chromosom mitochondrialny (NC_006853.1), region chromosomu X (NC_082638.1) oraz liczne niezlokalizowane scaffoldy (NW_020190xxx.1).

2. TAGI MM/ML — INFORMACJA O METYLACJI W PLIKACH BAM

Oba pliki BAM zawierają tagi MM (modyfikacje zasad) oraz ML (prawdopodobieństwa modyfikacji) zgodnie ze specyfikacją SAM/BAM (hts-specs v1.6+).

Inspekcja tagu MM w próbce A:

MM:Z:C+h?,<positions>;C+m?,<positions>;

ML:B:C,<probabilities>

Oznacza to:

C+h = prawdopodobieństwa 5-hydroksymetylocytozyny (5hmC)
w pozycjach CpG

C+m = prawdopodobieństwa 5-metylocytozyny (5mC)
w pozycjach CpG

Końcowy znak „?” oznacza, że nieobserwowane cytozyny są pomijane (tryb implicit no-call), co jest standardowym formatem wyjściowym Dorado.

Próbka B dodatkowo zawiera 6mA (N6-metyladeninę) w poleceniu basecallingu, jednak analiza modkit pileup skupiała się tutaj wyłącznie na 5mC i 5hmC (--modified-bases 5mC 5hmC --combine-mods), łącząc oba typy modyfikacji w jeden wspólny wskaźnik metylacji dla każdego miejsca CpG.

Wniosek: Oba pliki BAM są w pełni przygotowane do analizy metylacji.
Tagi MM/ML są obecne i poprawnie sformatowane do dalszego przetwarzania w modkit.

3. MAPOWANIE DO GENOMU REFERENCYJNEGO BYDŁA

Aligner: Dorado v0.7.0 (wewnętrzny minimap2 2.27-r1193, preset ONT)

Referencja: Bos taurus (bos_taurus.fa) — 1,958 sekwencji referencyjnych

Metryka Próbka A Próbka B

Wszystkie rekordy BAM 3,764,411 2,368,994

Primary reads 3,230,105 1,619,182

Secondary alignments 411,370 603,622

Supplementary alignments 122,936 146,190

Zmapowane (wszystkie) 1,972,418 (52.4%) 2,339,547 (98.8%)

Zmapowane primary 1,438,112 (44.5%) 1,589,735 (98.2%)

Niezmapowane primary 1,791,993 (55.5%) 29,447 (1.8%)

Najważniejsze obserwacje:

- Próbka B mapuje się niemal całkowicie do genomu bydła (98.8%), co wskazuje na wysoką konserwację sekwencji między Bison bonasus a Bos taurus.
- Próbka A ma znacznie niższy poziom mapowania (44.5% primary). Prawdopodobnie wynika to z:
 - (a) niższej jakości basecallingu (simplex vs duplex),
 - (b) większej dywergencji genetycznej tego osobnika,
 - (c) obecności odczytów z regionów nieobecnych w genomie bydła.
- Duża liczba niezmapowanych odczytów (~1.8 mln) wymaga dalszej analizy.
- Próbka A ma niższe pokrycie genomu (~1–3× na autosomach), podczas gdy próbka B osiąga ~5–10×.
- Obie próbki wykazują wiele alignments wtórnych, co jest typowe dla długich odczytów mapujących się do regionów powtarzalnych.

4. ŚREDNIA METYLACJA WEDŁUG CHROMOSOMÓW — OBA OSOBNIKI

Metoda: modkit pileup z --cpg --combine-strands --combine-mods
--modified-bases 5mC 5hmC

Wartości przedstawiają średnie ważone
(suma zmodyfikowanych odczytów / suma wszystkich odczytów)
dla wszystkich miejsc CpG na chromosom.

Chromosom Meth_A (%) Meth_B (%) Różnica A-B (pp)

chr1 90.98 81.45 +9.53

chr2 89.89 78.53 +11.36

chr3 88.96 78.85 +10.11

...

chr27 90.07 73.92 +16.14

chr30 91.09 76.81 +14.28

chrMT 21.30 5.14 +16.16


ŚREDNIA

autosomalna 89.76 79.45 +10.31

5. WYKRESY PORÓWNUJĄCE CHROMOSOMY


Methylation Difference per Chromosome (Sample A – Sample B)


Positive values = higher methylation in Sample A



Average CpG Methylation per Chromosome


Weighted mean across all CpG sites reported by model pileup






CpG Methylation: Sample A vs Sample B


Per-site comparison — genome-wide subsample of 100,000 sites (coverage $\geq 5\times$ in both samples)




CpG Methylation per Chromosome Sample A vs Sample B



Distribution of CpG Methylation (per-site % methylation)





NAJBARDZIEJ RÓŻNICUJĄCE SIĘ POZYCJE CpG

(top 20, pokrycie $\geq 5\times$ w obu próbkach)

Chromosom	Pozycja	Meth_A (%)	Meth_B (%)	Różnica
chr1	23,761,878	100.0	0.0	+100.0
chr3	32,210,419	100.0	0.0	+100.0
chr4	55,322,644	100.0	0.0	+100.0

...

Przy pokryciu $5\times$ wartości 100% vs 0% mogą nadal wynikać z zaledwie 5 odczytów. Takie ekstremalne miejsca należy interpretować ostrożnie.

7. KANDYDUJĄCE REGIONY DMR

Metoda:

okna 500 kb, minimum 5 wspólnych miejsc CpG
(pokrycie $\geq 5\times$ w obu próbkach).

Najbardziej wiarygodne regiony DMR:

Region	Średnia_A	Średnia_B	Różnica
NW_020190941.1	75.3	31.1	+44.3
chr4:108.5-109.0 Mb	100.0	58.4	+41.6
chr17:27.5-28.0 Mb	97.2	60.3	+36.9

...

Regiony na scaffoldach NW_* z dużą liczbą miejsc CpG są najbardziej wiarygodnymi kandydatami DMR.

8. INTERPRETACJA BIOLOGICZNA I TECHNICZNA

INTERPRETACJA BIOLOGICZNA

1. Globalna hipometylacja w próbce B (~10 pp niższa):
Może wynikać z:
 - o różnic tkankowych,
 - o wieku rozwojowego,
 - o różnic płciowych,
 - o rzeczywistej zmienności epigenetycznej między osobnikami.
2. Metylacja mitochondrialna:
DNA mitochondrialne u ssaków jest zwykle niemal niemetylowane.
Obserwowane wartości prawdopodobnie wynikają z szumu technicznego.
3. chr27 i chr30:
Wykazują największe różnice autosomalne (+16.1 i +14.3 pp),
ale niskie pokrycie próbki A ogranicza wiarygodność tych wyników.
4. Konstytutywnie niemetylowane miejsca:
Spadki metylacji obserwowane w obu próbkach prawdopodobnie odpowiadają
wyspom CpG w promotorach genów.

INTERPRETACJA TECHNICZNA

1. Artefakty mapowania międzygatunkowego:
Żubr i bydlę rozdzieliły się ewolucyjnie ~1–2 mln lat temu.
Dywergencja sekwencji (~5%) może powodować:
 - o błędne mapowanie,
 - o utratę odczytów,
 - o fałszywe sygnały metylacji.
2. Simplex vs duplex:
Duplex (próbka B) ma znacznie wyższą dokładność (~Q30)
niż simplex (~Q20), co poprawia:
 - o mapowanie,
 - o jakość wywoływania metylacji.
3. Asymetria pokrycia:
Niskie pokrycie w próbce A powoduje zawyżenie liczby wyników
0%/100%.
4. Flaga --combine-mods:
5mC i 5hmC zostały połączone w jedną kategorię,
przez co utracono informację biologiczną o różnicach
między tymi modyfikacjami.

9. ODPOWIEDZI NA PYTANIA SZCZEGÓŁOWE

P1: Czy różnice metylacji są równomiernie rozłożone?

O: Tak. Większość autosomów wykazuje różnice około +9–11 pp, co sugeruje globalną różnicę metylacji genomowej.

P2: Na których chromosomach różnice są największe?

O: chrMT (+16.2 pp), chr27 (+16.1 pp), chr30 (+14.3 pp).

P3: Co jest bardziej informacyjne - pojedyncze CpG czy regiony?

O: Regiony DMR są znacznie bardziej wiarygodne biologicznie i statystycznie niż pojedyncze miejsca CpG.

P4: Jakie błędy wynikają z mapowania żubra do genomu bydła?

O:

- utrata odczytów,
- błędne mapowanie,
- wpływ SNP na metylację,
- problemy ze zmianami strukturalnymi,
- bias referencyjny.

P5: Jak odróżnić sygnał biologiczny od efektów pokrycia?

O:

- stosować próg pokrycia $\geq 5\times$ lub $\geq 10\times$,
- analizować regiony zamiast pojedynczych miejsc,
- filtrować po MAPQ,
- używać narzędzi statystycznych (DSS, methylKit, metilene).

P6: Czy można wyciągać wnioski populacyjne z dwóch osobników?

O: Nie.

Przy $n=1$ na grupę nie można oszacować wariancji biologicznej ani przeprowadzić poprawnych testów statystycznych.

Dane mają charakter eksploracyjny i generują hipotezy do dalszej walidacji.